

PROPUESTA TÉCNICA Y ESTRATÉGICA: OPTIMIZACIÓN DEL RENDIMIENTO FINANCIERO EN EL ALQUILER VACACIONAL MEDIANTE IA PREDICTIVA

Proyecto de Innovación PropTech

Cargo: Responsable de I+D en IA

Estudiante: Alex Tumiri Huanca

Empresa: PropTech Solutions España S.L.

Sector: Real Estate & Hospitality Tech

Fecha: 24 de abril de 2026

ÍNDICE

1. Introducción y definición del problema.....	3
1.1 Presentación de la empresa y sector de actividad.....	3
1.2 Identificación del problema clave.....	4
1.3 Justificación de la relevancia empresarial.....	4
2. Estado del arte y análisis de tendencias en IA.....	5
2.1 Revisión de tendencias y avances en IA aplicados al sector seleccionado.....	5
2.2 Referencias a estudios recientes y casos de uso similares.....	5
2.3 Identificación de enfoques previos y evaluación de sus limitaciones.....	6
3. Estrategia de investigación aplicada a IA.....	7
3.1 Alcance del proyecto.....	7
3.2 Planteamiento de hipótesis.....	8
3.3 Objetivos del proyecto (SMART).....	8
3.4 Metodología General.....	8
3.5 Fuentes de datos y descripción de requerimientos.....	8
4. Plan de implementación y validación.....	10
4.1 Fases del proyecto: Roadmap de 14 semanas.....	10
4.2 Validación de la solución y métricas de éxito.....	12
A. Métricas Técnicas de Predicción.....	12
B. Métricas de Impacto en Negocio.....	13
4.3 Resultados Simulados y Comparativa de Modelos.....	13
5. Conclusiones y recomendaciones estratégicas.....	14
6. Referencias Bibliográficas.....	15

1. Introducción y definición del problema

1.1 Presentación de la empresa y sector de actividad

PropTech Solutions España S.L. es una entidad tecnológica especializada en la gestión dinámica de activos inmobiliarios destinados al alquiler vacacional y de corta estancia (Short-Term Rental). La organización actúa como intermediario tecnológico entre los propietarios de inmuebles y los grandes ecosistemas de reserva globales, principalmente Airbnb y Booking.com. El sector ProTech en España ha experimentado un crecimiento exponencial en la última década, transformándose de un modelo de gestión manual a uno basado estrictamente en el análisis de datos masivos (Big Data).

La empresa no solo se encarga del mantenimiento y atención al cliente. Su valor diferencial reside en el 'PricingAlgorithm', una herramienta interna encargada de determinar cuánto debe costar una noche de estancia en función de la rentabilidad esperada por los propietarios (partners).

1.2 Identificación del problema clave

El problema central identificado radica en la rigidez del sistema de cotización actual. El algoritmo vigente opera bajo un modelo de regresión lineal estático y un conjunto de reglas heurísticas (if-then) que no logran capturar la complejidad multidimensional del mercado español. Los puntos de fallo críticos son:

- **Subestimación del valor de las amenidades:** El sistema actual trata de forma genérica elementos como el inventario de cocina o el tipo de descanso. No distingue adecuadamente el impacto en el precio de una cafetera de cápsulas premium frente a una estándar, o la diferencia en la disposición a pagar por una cama "King Size" frente a camas individuales.
- **Falta de adaptabilidad contextual:** La empresa cuenta con datos estructurados alojados en el Data Warehouse corporativo (vía SQL) que se visualizan en Metabase sobre el estado del inmueble, pero estos no se cruzan de forma inteligente con factores externos como el clima, la cercanía a medios de transporte específicos o la densidad de zonas turísticas en

tiempo real.

- **Desajuste en la rentabilidad:** Esta incapacidad de predicción genera pérdidas de ingresos por subvaloración o aumento crítico de la tasa de desocupación por sobrevaloración del mercado.

Existe un "gap" crítico: los modelos actuales no integran adecuadamente características contextuales dinámicas ni la granularidad necesaria en las amenidades de los inmuebles, lo que resulta en precios que no capturan el valor real de la estancia.

1.3 Justificación de la relevancia empresarial

La precisión en el precio impacta directamente en el RevPAR (Revenue Per Available Room). Un error del 5-10% en la estimación diaria supone pérdidas acumuladas significativas. La transición hacia modelos de IA avanzados permitirá optimizar la ocupación y el margen de beneficio, reduciendo el riesgo de vacancias y aumentando la fidelidad de los partners.

2. Estado del arte y análisis de tendencias en IA

2.1 Revisión de tendencias y avances en IA aplicados al sector seleccionado

La industria del alquiler vacacional ha experimentado una transición radical de modelos de precios fijos o estacionales hacia sistemas de **Dynamic Pricing** basados en Big Data. La tendencia actual se centra en la adopción de algoritmos de **Gradient Boosting Machine (GBM)**, como XGBoost, debido a su capacidad para manejar la escasez de datos y su escalabilidad masiva (Chen & Guestrin, 2016).

Los avances más recientes integran el aprendizaje profundo y el procesamiento de lenguaje natural (NLP) para transformar datos no estructurados en variables predictivas. La tendencia "SOTA" (State-of-the-Art) ya no solo considera cuántas habitaciones tiene un inmueble, sino cómo se describen emocionalmente y qué tan cerca están de puntos de interés micro-localizados mediante el uso de **Spatial Data Modeling**.

2.2 Referencias a estudios recientes y casos de uso similares

La literatura científica actual respalda la superioridad de los modelos de ensamble frente a los métodos estadísticos tradicionales.

Wan et al. (2025) realizaron un estudio empírico exhaustivo en el que compararon modelos como la regresión lineal, random forest y XGBoost. Sus resultados demostraron que XGBoost no solo minimiza el error de predicción, sino que también captura mejor las interacciones no lineales entre variables como la ubicación y la reputación del anfitrión, logrando un rendimiento superior en mercados de alta densidad.

Por otro lado, Islam et al. (2022) introdujeron una innovación clave al emplear Latent Dirichlet Allocation (LDA) para extraer tópicos a partir de descripciones de alojamientos. Al combinar estos con técnicas de filtrado espacial (MESF) y XGBoost, lograron capturar el valor subjetivo percibido por los huéspedes.

Asimismo, Pittala et al. (2024) analizaron patrones de precios en ciudades europeas, identificando que variables como la distancia al metro, el índice de atracciones cercanas y el estatus de Superhost son determinantes críticos.

Finalmente, Ji et al. (2024), basándose en un conjunto de datos de 75,000 registros, demostraron que la flexibilidad en las políticas de cancelación y la calidad de las amenidades influyen directamente en la disposición de pago del cliente.

2.3 Identificación de enfoques previos y evaluación de sus limitaciones

Históricamente, el sector ha dependido de dos enfoques principales que hoy se consideran insuficientes:

Enfoque Previo	Descripción	Limitaciones Identificadas (Gaps)
Regresión Lineal Simple	Modelos basados en la suma ponderada de características básicas (m2, habitaciones).	Incapacidad para capturar relaciones no lineales complejas y alta sensibilidad a valores atípicos (Wan et al., 2025).
Heurísticas Estacionales	Ajustes manuales basados en "temporada alta/baja" y fines de semana.	No reaccionan a eventos en tiempo real ni a cambios repentinos en la demanda local o competencia.
Random Forest Estándar	Uso de bosques de decisión para capturar no linealidades.	Suele presentar mayor sesgo que el Boosting y tiene dificultades para extrapolar tendencias en datos tabulares con alta varianza.

La limitación más severa de los enfoques previos es el **"Desprecio Espacial y Textual"**. La mayoría de los modelos anteriores trataban la ubicación como una variable categórica simple (ej. código postal) y las descripciones como ruido. La propuesta actual supera esto integrando el contexto semántico y la autocorrelación espacial como pilares del aprendizaje (Islam et al., 2022).

3. Estrategia de investigación aplicada a IA

3.1 Alcance del proyecto

El proyecto plantea la sustitución del motor de reglas por un modelo de regresión de ensamble (**XGBoost/CatBoost**). La solución abarca desde la ingesta de datos estructurados provenientes del Data Warehouse corporativo (vía SQL) hasta la entrega de una sugerencia de precio diario optimizada para partners de Airbnb y Booking.com, integrando amenidades granulares, variables contextuales dinámicas y análisis de sentimiento por NLP así como variables climáticas y de localización.

3.2 Planteamiento de hipótesis

Hipótesis: "La implementación de un modelo de Gradient Boosting con ingeniería de características enriquecida (amenidades granulares, variables contextuales dinámicas, variables climáticas y de localización, análisis de sentimiento por NLP) permitirá reducir el Error Medio Absoluto (MAE) en un 25% respecto al sistema actual."

3.3 Objetivos del proyecto (SMART)

- **Específico:** Desarrollar un motor de IA dinámico para la predicción de precios en el mercado de alquiler vacacional español.
- **Medible:** Lograr un MAPE inferior al 9% en el set de validación histórica.
- **Alcanzable:** Utilizando el stack tecnológico de Python y los datos estructurados provenientes del Data Warehouse corporativo (vía SQL), enriquecidos con APIs externas.
- **Relevante:** Impactar directamente en el incremento del RevPAR y la tasa de ocupación.
- **Temporal:** Ejecución total en un cronograma de 14 semanas.

3.4 Metodología General

Se adoptará la metodología CRISP-DM, con énfasis en las fases de comprensión del negocio y comprensión de los datos (incluyendo análisis mediante Metabase), seguido de feature engineering (cálculo de distancias y puntajes de amenidades), modelado (utilizando XGBoost) y evaluación técnica. Esta última se realizará mediante validación cruzada temporal, con el objetivo de garantizar la estabilidad del modelo frente a la estacionalidad del turismo en España.

3.5 Fuentes de datos y descripción de requerimientos

Para garantizar el éxito del modelo predictivo, se requiere la consolidación de un dataset multidimensional que abarque las siguientes categorías de datos:

Categoría	Variables Específicas Requeridas	Justificación Técnica
Estructurales	Tipo de propiedad, capacidad (personas), número de dormitorios/baños, tipo de habitación.	Establecen el precio base y la categoría del inmueble (Pittala et al., 2024).
Geoespaciales	Coordenadas exactas (lat/lng), distancia al centro urbano, cercanía al metro, índices de restauración.	La ubicación es el predictor de precio más crítico en Real Estate (Islam et al., 2022).
Amenidades	WiFi, aire acondicionado, cocina, parking, calidad de electrodomésticos, políticas	Las amenidades de calidad justifican primas de precio (Ji et al., 2024).

Categoría	Variables Específicas Requeridas	Justificación Técnica
	de cancelación.	
NLP (Texto)	Descripciones de anfitriones y texto completo de reseñas de huéspedes.	Modelado de tópicos (LDA) para capturar el valor subjetivo del inmueble (Islam et al., 2022).
Reputación	Estatus de Superhost, ratio de respuesta, puntuación de limpieza y satisfacción general.	La confianza del usuario reduce la elasticidad del precio.

4. Plan de implementación y validación

4.1 Fases del proyecto: Roadmap de 14 semanas

Para asegurar una base teórica sólida y una validación exhaustiva, el ciclo de vida del proyecto se ha estructurado en 14 semanas, incorporando una fase inicial de investigación profunda:

Semanas	Fase	Actividades Clave	Entregable
1-2	Fase 1: Investigación y Estado del Arte	Análisis detallado de literatura científica sobre AVM y Pricing dinámico. Definición de la arquitectura base del modelo.	Documento de Arquitectura y Referencial Teórico.
3-4	Fase 2: Ingesta y Preparación de Datos	Extracción de métricas de datos estructurados provenientes del Data Warehouse corporativo (vía SQL) y limpieza de datos históricos. Integración de fuentes externas.	Dataset de entrenamiento curado.
5-6	Fase 3: Ingeniería de Características	Creación de variables de "Distancia a PDI", "Integración de API histórica/predictiva de clima" y "Scoring de Amenidades" (equipamiento de cocina, mobiliario de descanso y conectividad, clima).	Matriz de características (Feature Set).

Semanas	Fase	Actividades Clave	Entregable
7-10	Fase 4: Desarrollo y Modelado de IA	Entrenamiento de modelos competitivos (XGBoost, Random Forest). Optimización de hiper parámetros.	Algoritmo Predictivo v1.0.
11-12	Fase 5: Validación Técnica y Backtesting	Pruebas de error (MAE, RMSE, MAPE) sobre datos históricos de 2024-2025. Evaluación de sobreajuste.	Informe Técnico de Validación.
13-14	Fase 6: Evaluación de Impacto y Pilotaje	Simulación de rentabilidad (RevPAR) y diseño del plan de despliegue en producción.	Propuesta Final de Implementación.

4.2 Validación de la solución y métricas de éxito

Para comprobar la efectividad de la propuesta, se utilizará un marco de validación dual que integra métricas de precisión técnica y métricas de impacto en negocio.

A. Métricas Técnicas de Predicción

- **MAE (Mean Absolute Error):** Mide el promedio de los errores absolutos entre la predicción y el precio real. Es la métrica más interpretable financieramente (Euros de error promedio).

Objetivo: Reducción del 25% respecto al sistema actual.

- **RMSE (Root Mean Square Error):** Penaliza de forma cuadrática los errores grandes. Es vital para asegurar que el modelo no cometa errores de precio "extremos" que resulten en pérdidas críticas.
- **MAPE (Mean Absolute Percentage Error):** Expresa el error como un porcentaje. Permite comparar la precisión entre inmuebles de lujo (precios altos) y económicos (precios bajos) de forma equitativa.

Objetivo SOTA: 9%.

B. Métricas de Impacto en Negocio

- **Revenue Lift:** Incremento porcentual en los ingresos totales comparando un grupo de control (precio tradicional) vs un grupo experimental (precio IA).
- **RevPAR (Revenue Per Available Room):** El RevPAR se define como el indicador de desempeño fundamental del sector. Mide el éxito combinando la tasa de ocupación con el precio promedio diario.

4.3 Resultados Simulados y Comparativa de Modelos

A continuación se presenta una simulación del rendimiento esperado basada en la integración de datos geoespaciales y NLP en la arquitectura XGBoost:

Modelo Evaluado	MAE (Simulado)	MAPE (%)	Revenue Lift Proyectado
Regresión Lineal (Baseline)	€18.40	14.2%	0.0%
Random Forest	€15.10	11.5%	+4.2%
XGBoost + Geo + NLP (Propuesta)	€13.80	8.1%	+9.5%

5. Conclusiones y recomendaciones estratégicas

La presente investigación y el análisis de la arquitectura propuesta permite concluir que la transición hacia modelos de ensamble de alto rendimiento, específicamente **XGBoost** y **CatBoost**, constituye un cambio de paradigma fundamental frente a las aproximaciones lineales o heurísticas tradicionales. Esta capacidad técnica facilita la captura de interacciones no lineales y oportunidades de ingresos que suelen ser omitidas sistemáticamente por sistemas convencionales, permitiendo una adaptación superior a la volatilidad del mercado inmobiliario (Wan et al., 2025).

Asimismo, la integración estratégica de datos no estructurados mediante el Procesamiento de Lenguaje Natural (NLP) y la asignación de tópicos a través de **Latent Dirichlet Allocation (LDA)** se identifica como el factor crítico de diferenciación competitiva. Al transformar la subjetividad de las reseñas en variables cuantitativas de sentimiento y calidad, la organización adquiere la capacidad de transitar de una tarificación basada meramente en el inventario físico a una fundamentada en la "experiencia validada", lo cual justifica primas de precio de entre el 5% y 7% sobre la competencia local (Islam et al., 2022).

En términos de impacto financiero, la reducción proyectada del **25% en el Error Medio Absoluto (MAE)** asegura una optimización robusta del **RevPAR** y una mayor estabilidad en el flujo de caja para los propietarios. No obstante, se establece como recomendación imperativa la automatización de los pipelines de datos geoespaciales, dado que la precisión del modelo es altamente sensible a la "micro-ubicación" y los servicios periféricos (Pittala et al., 2024).

Finalmente, la sostenibilidad del liderazgo de la empresa en el sector PropTech dependerá de la ejecución de líneas de investigación futuras orientadas a la **Visión Artificial (CNN)** para el análisis estético de activos, la integración de eventos en tiempo real y la adopción de **IA Explicable (XAI)** mediante técnicas SHAP. Este enfoque no solo incrementará la precisión técnica, sino que fomentará la transparencia y la confianza de los anfitriones, alineando la tecnología con las demandas de sostenibilidad y personalización del mercado actual.

6. Referencias Bibliográficas

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794).

Islam, M. D., Li, B., Islam, K. S., Ahasan, R., Mia, M. R., & Haque, M. E. (2022). Airbnb rental price modeling based on Latent Dirichlet Allocation and MESF-XGBoost composite model. *Machine Learning with Applications*, 7, 100208.

Ji, R., Huang, X., Qian, Y. (2024). Dynamic pricing in short-term rentals: An empirical examination of Airbnb listings. En *Proceedings of the 3rd International Conference on Financial Technology and Business Analysis* (pp. 162-171).

Pittala, T. S. S. R., Meleti, U. M. R., & Vasireddy, H. (2024). Unveiling patterns in European Airbnb prices: A comprehensive analytical study using machine learning techniques. *arXiv preprint arXiv:2407.01555*.

Wan, X., Li, X., Xiong, L., Xu, Y., & Tian, J. (2025). Comparison and optimization strategies of Airbnb rental prediction models: An empirical study based on linear regression, XGBoost and Random Forest. En *Proceedings of ICEMGD 2025 Symposium: Innovating in Management and Economic Development* (pp. 162-170).