

Detección de odio en redes sociales

Este proyecto está integrado por cinco asignaturas del máster. En cada una de ellas irás trabajando una parte del proyecto integral para un **piloto experimental** de la SureTech Innovations. En cada una de las actividades avanzarás en el desarrollo de este piloto experimental para que la empresa logre su objetivo, desarrollar un **sistema inteligente** capaz de **detectar odio en los mensajes** entre sus empleados.

La detección de odio en redes sociales es un tema que preocupa mucho a la empresa SureTech Innovations. Para ellos es importante por varias razones, como, por ejemplo:

- ▶ **Protección de usuarios:** la detección de contenido odioso ayuda a proteger a los usuarios de las redes sociales al identificar y mitigar mensajes que pueden ser ofensivos, amenazantes o perjudiciales.
- ▶ **Prevención del ciberacoso:** la detección de odio es crucial para abordar el ciberacoso. Identificar y abordar mensajes ofensivos ayuda a prevenir la propagación del odio y proteger a las víctimas de comportamientos dañinos.
- ▶ **Preservación de la diversidad y la inclusión:** las redes sociales son plataformas donde diversas comunidades interactúan. La detección de odio es esencial para preservar la diversidad y fomentar la inclusión, evitando la discriminación y la exclusión basada en características personales.
- ▶ **Mantenimiento de la reputación:** las empresas y organizaciones utilizan las redes sociales para interactuar con sus audiencias. La detección de contenido odioso es crucial para proteger la reputación de estas entidades, evitando que se asocien con mensajes perjudiciales o polémicos.
- ▶ **Cumplimiento legal y normativo:** en muchos lugares, el discurso de odio está prohibido por la ley. Las plataformas de redes sociales tienen la responsabilidad de cumplir con las regulaciones y tomar medidas para prevenir la propagación de contenido ilegal o perjudicial.

En SureTech Innovations están preocupados por el **alarmante número de mensajes de odio** que hoy en día se realizan en redes sociales, y les gustaría usar sus avances tecnológicos para detectar la presencia de *haters* en redes sociales. Este proyecto quieren aplicarlo al idioma propio de la empresa, que es en castellano.

El equipo de SureTech Innovations quiere plantear un desarrollo experimental de un **clasificador de mensajes de odio**. Para ello, necesitarán investigar sobre las diferentes **librerías y herramientas** para realizar su proyecto. Además, será necesario investigar en términos de rendimiento, eficiencia y precisión de **diferentes técnicas de clasificación**, tanto de **machine learning** clásico, como de métodos de **deep learning**. Finalmente, la empresa desea elaborar un informe en donde se explique como son los mensajes de odio, caracterizando los patrones comunes que existen en estos mensajes.

Etapas del proyecto

Para dar respuesta al proyecto planteado, en cada una de las **asignaturas seleccionadas** para el proyecto transversal se propone **abordar un punto diferente** del desarrollo del proyecto. Así, al acabar el curso se habrá conseguido el objetivo de la empresa SureTech que es desarrollar un sistema inteligente capaz de clasificar mensajes de odio.

Objetivos de aprendizaje del proyecto

El proyecto propuesto se enmarca dentro dos ramas de la IA: *machine learning*, *deep learning* y procesamiento del lenguaje natural, por lo que se plantean los siguientes objetivos de aprendizaje:

- **Desarrollar un modelo preciso:** implementar un modelo de clasificación que sea preciso en la predicción de clases o categorías específicas en nuevos conjuntos de datos.

- ▶ **Explorar y preprocesar datos:** realizar un análisis exploratorio de datos para comprender la distribución y la naturaleza de las características.
- ▶ **Seleccionar características relevantes:** identificar y seleccionar las características más relevantes para la tarea de clasificación, eliminando posiblemente aquellas que no aporten información significativa al modelo.
- ▶ **Optimizar hiperparámetros:** ajustar los hiperparámetros del modelo de *machine learning* para mejorar su rendimiento y generalización en diferentes conjuntos de datos.
- ▶ **Evaluar el rendimiento del modelo:** utilizar métricas de evaluación de clasificación, como precisión, recall, F1-score y matriz de confusión, para medir el rendimiento del modelo en conjuntos de prueba y validación.
- ▶ **Manejar el desequilibrio de clases:** abordar posibles desequilibrios en la distribución de las clases, aplicando técnicas como el sobremuestreo, submuestreo o el uso de pesos de clase para mejorar la capacidad del modelo para predecir clases minoritarias.
- ▶ **Interpretar resultados y características:** interpretar los resultados del modelo, analizar la importancia de las características y comprender cómo estas afectan las predicciones del modelo.
- ▶ **Desplegar el modelo:** preparar el modelo para su despliegue en un entorno de producción, asegurándose de que sea fácilmente integrable y escalable.
- ▶ **Documentar y comunicar:** documentar todo el proceso, desde la recopilación de datos hasta la implementación del modelo y comunicar claramente los resultados y las limitaciones de este a las partes interesadas.

Dataset

Para el desarrollo de este proyecto, se hará uso de la **librería de expresiones de odio detectado en medios informativos digitales en España**, resultado del proyecto Hatemedia (proyecto PID2020-114584GB-I00), financiado por M C I N / AEI /10.13039/501100011033.

Said-Hung, E., Römer Pieretti, M., Montero-Díaz, J., De Lucas Vicente, A. y Torres, J. M. (30 de marzo de 2023). *Hate Speech Library in Spanish / Librería de odio en Español*. Figshare. <https://doi.org/10.6084/m9.figshare.22383643.v2>

La base de datos muestra los 7210 lemas simples y compuestos más repetidos y que, desde el punto de vista semántico, tienden al odio en los medios informativos digitales en España. La elaboración de este documento final requirió las siguientes fases:

- ▶ **Etiquetado de expresiones y extracción de lemas.** En la primera fase, se recolectaron durante el mes de enero un total de 1 100 742 mensajes asociados a medios informativos digitales en España. De estos se excluyeron un total de 776 356 mensajes por estar duplicados o repetidos, lo que dejó un total de 324 395 mensajes en los que un 4,06 % estaban asociados con expresiones que tendían al odio. Del total de mensajes identificados se eliminaron *stop-words*, se identificaron datos anómalos (que no pertenecían a un idioma conocido o eran diminutivos de este) y se revisaron manualmente para identificar tanto los lemas simples como los compuestos que tendían al odio.
- ▶ **Identificación de duplicados.** En la primera fase se realizaron dos listados, el primero de lemas simples y el segundo de lemas compuestos. El primer paso fue filtrar estas dos listas para identificar lemas repetidos para obtener dos bibliotecas donde cada lema aparece una sola vez.
- ▶ **Integración BBDD.** A continuación, en la tercera fase, se procedió a unir ambas bibliotecas para construir una biblioteca final que integrara todos los lemas, tanto simples como compuestos. Finalmente, se realizó un filtrado final para asegurar que no se repitan los lemas.

Para más información sobre el proyecto Hatemedia accede a la siguiente página web:

<https://www.hatemedia.es/>

Disponibilidad del dataset

Además de la colección de lemas simples y compuestos, se tiene acceso al dataset completo recolectado por el proyecto Hatemedia. A continuación, se presenta toda la documentación del dataset que se debe utilizar en el proyecto:

► Acceso al informe sobre la recolección de datos:

- Ruiz-Iniesta, A., Blanco Valencia, X., Pérez, D.; de Gregorio Vicente, O., José Cubillas, J. y Montero Díaz, J. (2024). <https://orcid.org/0000-0002-4145-7424>.
- Said Hung, E. y Montero Díaz, J. (2024). *Informe final sobre el scrapeo de datos brutos obtenidos en medios informativos digitales españoles en X*. Figshare. <https://doi.org/10.6084/m9.figshare.25187591>

► Acceso a los datos brutos recolectados:

- Said-Hung, E., Montero-Díaz, J., Ruíz-Iniesta, A., Blanco-Valencia, X., Pérez-Palau, D., De Gregorio-Vicente, O. y Cubillas, J. (2024). *Datos brutos de mensajes publicados en usuarios vinculados a medios informativos digitales españoles en X, FB y Web* [Data set]. Hatemedia Project. <https://doi.org/10.6084/m9.figshare.25222118.v3>
- Acceso a los datos recopilados en un único CSV
 - Este CSV es una adaptación de los datos publicados en el trabajo publicado en <https://doi.org/10.6084/m9.figshare.25222118.v3>.
Conservando la licencia original, los términos de licencia de este dataset son <https://creativecommons.org/licenses/by/4.0/>
Puedes descargar los datos en el siguiente enlace: Said-Hung, E. (2025). Dataset ejemplo de datos recabados en Hatemedia [Data set]. Hatemedia Project. <https://doi.org/10.5281/zenodo.17523064>